

Controle de qualidade de imagem usando aprendizado de máquina

Um exercício de computador usando o software CellProfiler e CellProfiler Analyst

Beth Cimini

Broad Institute do MIT e Harvard, Cambridge, MA

Informações sobre o histórico:

A análise de imagens de alta qualidade depende de imagens de alta qualidade para analisar; o chamado princípio ‘**Entra lixo, sai lixo**’. Se o seu conjunto de imagens for pequeno, é simples curá-lo e remover imagens que não estejam em foco ou que contenham detritos que possam atrapalhar a segmentação. Em uma tela de alto conteúdo contendo dezenas ou centenas de milhares de imagens, isso é essencialmente impossível.

As imagens neste experimento vêm da [Broad Bioimage Benchmark Collection](#). Eles são 240 dos 69.120 campos de células U2OS tratados com um painel de 1.600 compostos bioativos conhecidos e fotografados em cinco canais para um chamado ensaio CellPainting - consulte Gustafsdottir et al, 2013 para obter mais informações. Dado o grande tamanho deste experimento, foi necessário criar um método automatizado de controle de qualidade.

Para saber mais sobre aprendizado de máquina para controle de qualidade de imagem, consulte Bray et al 2012 e suas referências.

Objetivos deste exercício:

Este exercício ensinará como medir aspectos da qualidade da imagem com o CellProfiler e como usar as ferramentas de aprendizado de máquina no CPA para criar regras robustas para distinguir imagens de baixa qualidade. Além disso, mostrará como incorporar essas regras em um pipeline de análise de imagem para que elas possam orientar a análise de dados downstream.

Materiais necessários para este exercício:

Essas 1.200 imagens (240 locais em 5 canais) representam 120 poços de uma única placa de 384 poços, tratados com DMSO ou com uma variedade de compostos bioativos.

Além disso, espera-se que você esteja familiarizado com as ferramentas do CellProfiler e do CellProfiler Analyst, de preferência após concluir o tutorial Translocation ou um exercício introdutório semelhante.

1. Start the provided QC pipeline on the BBBCo22 dataset

Para fazer o controle de qualidade, precisamos primeiro medir as imagens de várias maneiras. Isso nos permitirá fazer o aprendizado de máquina para usar as medições e identificar as imagens boas das ruins.

- Inicie o CellProfiler clicando duas vezes no ícone da área de trabalho: 
- Arraste e solte o arquivo ‘BBBCo22_QC.cpipe’ na caixa ‘Módulos de análise’. Três módulos devem aparecer - duas cópias de ‘MeasureImageQuality’ e um módulo **ExportToDatabase**.
- Arraste e solte a pasta “BBBCo22_20585_AE” na caixa “Lista de arquivos”. Ela deverá ser preenchida automaticamente.
- Pressione o botão Analyze Images (Analisar imagens).
- Você receberá um pop-up de erro - ‘Não foram definidas instâncias anteriores do grupo de objetos. Tem certeza de que deseja continuar?’. Pressione “Yes” (Sim).

- Isso se deve ao fato de que não há objetos definidos no pipeline. Isso não afetará os resultados finais.
- O pipeline deve levar cerca de 10 a 15 minutos para ser executado. No final, três arquivos devem ser criados: um arquivo de banco de dados .db, um arquivo de texto .properties e um arquivo de texto .workspace.

2. Examine the QC pipeline (~15 minutes)

- Enquanto o pipeline estiver em execução, reserve algum tempo para examiná-lo e certificar-se de que entendeu as várias partes. Você provavelmente achará mais fácil abrir uma segunda janela do CellProfiler e abrir o pipeline nela.

Metadados

- As informações de placa, poço, local e canal estão sendo extraídas dos nomes de arquivos e pastas

NomesETipos

- As imagens são combinadas com seus canais por metadados e agrupadas por placa, poço e local

Grupos

- Esse módulo não é usado


Medir a qualidade da imagem

- ‘Incluir o valor de redimensionamento da imagem?’, ‘Calcular métricas de intensidade?’ e ‘Calcular métricas de saturação?’ estão todos definidos como sim. Abra o botão de ajuda  para ler sobre as medidas exportadas por cada uma dessas opções.
- ‘Calcular métricas de desfoque?’ está definido como sim e recebe múltiplas escalas espaciais – 2, 5, 10 e 20 pixels. Abra o botão de ajuda  para ler sobre os diferentes métodos usados para determinar se uma imagem está em foco.

Medir a qualidade da imagem

- Neste módulo de segunda imagem **MeasureImageQuality**, limites automáticos são calculados para as imagens ‘OrigHoechst’ e ‘OrigPh_golgi’ usando métricas de limite específicas. Leia sobre o motivo abrindo o botão de ajuda .
 - A escolha dessas duas imagens e desses dois métodos de limiarização não foi aleatória; ela corresponde aos métodos usados para segmentar núcleos e corpos celulares no pipeline de análise correspondente.

Exportar para banco de dados

Este módulo possui 4 partes principais, separadas por quebras ()

- **Criação do banco de dados:** essas opções determinam que tipo de banco de dados será criado (nesse caso, SQLite), se o CellProfiler deve sobrescrever ou adicionar dados existentes anteriormente e quais serão os nomes das tabelas.
- **Criação do arquivo de propriedades CPA:** essas opções predefinem alguns parâmetros para o CellProfiler Analyst para facilitar seu uso, como
 - Definir o tipo de placa como 384 e declarar que Image_Metadata_Plate e Image_Metadata_Well determinam a qual placa e poço atribuir cada imagem
 - Que cor atribuir a cada canal nas ferramentas de exibição de imagem do CellProfiler Analyst
 - Que você está classificando ‘Imagens’, não objetos


- **Criação do arquivo de espaço de trabalho CPA:** em vez de ter que explorar todos os parâmetros aleatoriamente para encontrar os recursos que separam as imagens boas das ruins, essas opções permitem a criação automática de gráficos para os recursos que provavelmente são os mais importantes. Aqui, preenchemos previamente 12 gráficos para você: 10 gráficos de dispersão e 2 histogramas.
- **Ajustes específicos do CellProfiler:** além de determinar o local do banco de dados de saída, a maioria dessas opções trata de como o CellProfiler deve tratar os objetos que identifica (se deve calcular médias/desvios padrão para todos eles, se deve combinar suas medidas em uma única tabela etc.). Como não estamos identificando nenhum objeto, não precisamos nos preocupar com isso.

3. Open the CellProfiler Analyst workspace and determine reasonable parameter cutoffs (~20 minutes)

Na primeira etapa do pipeline de controle de qualidade, analisaremos os gráficos de como várias medições estão distribuídas na população. Isso nos permite ter uma noção de quais são os valores “normais” para cada parâmetro. Estabeleceremos limites em torno dos valores “anormais” para uso posterior. Fique à vontade para criar gráficos e examinar parâmetros adicionais também se estiver interessado em explorar o conjunto de dados.

A identificação de primeira passagem das imagens anormais é importante, pois espera-se que elas sejam raras em nosso conjunto de dados geral. Ao identificar o maior número possível de imagens anormais nesta e na próxima etapa, esperamos ter um conjunto de treinamento grande e robusto o suficiente para que possamos treinar um bom classificador nas etapas posteriores.

- Assim que o pipeline for concluído, feche o CellProfiler e inicie o CellProfiler Analyst clicando duas vezes no ícone .
- Carregue o arquivo de propriedades que você acabou de criar.
- Vá para File-> Load Workspace (Arquivo-> Carregar espaço de trabalho). Devem ser criados 12 gráficos: 5 gráficos de dispersão sobre o foco (ImageNumber vs. ImageQuality_PowerLogLogSlope), 5 gráficos de dispersão sobre a supersaturação (ImageQuality_StdIntensity vs. ImageQuality_PercentMaximal) e 2 histogramas que mostram os limites automáticos calculados para os canais de núcleos e células.
- Para alguns ou todos os gráficos (de preferência, pelo menos dois de cada tipo), examine a forma dos dados. Há outliers óbvios presentes?
 - No menu suspenso “gate” (porta), selecione CREATE NEW GATE (criar nova porta) e dê a ela um nome (como “HighSat_ER” para outliers altos no gráfico de supersaturação do canal ER).
 - Desenhe o portão e clique com o botão direito do mouse (PC)/Command-click (Mac) para abrir uma janela. Você deverá ver duas opções denominadas ‘Show images in gate’ (uma ou ambas serão renomeadas na próxima versão do CPA para fins de clareza)
 - O de cima abrirá cada uma dessas imagens em uma janela separada. Geralmente, isso é mais fácil se apenas um pequeno número de imagens (<5) estiver no portão.
 - A parte inferior abrirá um visualizador de miniaturas com miniaturas de cada imagem; você pode clicar duas vezes na miniatura para abrir a imagem completa. Isso é muito mais rápido quando há muitas imagens dentro do portão.




*Figura 1: Examinando os objetos dentro de um portão.

- Observe algumas das imagens dentro do portal (talvez seja necessário clicar em “Show controls” (Mostrar controles) para ajustar o zoom, o contraste, etc.). Elas estão em foco e não têm detritos brilhantes? Se todas ou a maior parte delas parecerem de alta qualidade, ajuste o gate para ver um subconjunto diferente/menor ou exclua-o completamente usando o Gate Inspector (‘gate’-> ‘MANAGE GATES’).

4. Optional- use the PlateViewer tool to check for other features to gate on (~10 minutes)

Se você quiser ver se consegue encontrar recursos adicionais que possam distinguir imagens boas de imagens ruins, fique à vontade para explorar o conjunto de recursos mais detalhadamente.

- A ferramenta PlateViewer e escolha algumas medições do ImageQuality aleatoriamente ou use as teclas de seta para percorrer as medições para cima e para baixo.
 - Uma boa medição candidata será relativamente constante na maioria dos poços, mas terá um pequeno número de valores discrepantes (Fig. 2).
 - Quando você tiver um bom candidato, clique duas vezes em um poço com aberrações para abrir as imagens desse poço. Se um ou ambos parecerem muito aberrantes, talvez você queira examinar melhor essa medição.



*Figura 2: Uso da ferramenta PlateViewer para encontrar recursos que podem ser bons marcadores de imagens de baixa qualidade.

- Assim que tiver uma medida na qual gostaria de se basear, abra as ferramentas Histograma ou Gráfico de dispersão e faça o gráfico de todas as células com base nela (se estiver usando a ferramenta Gráfico de dispersão, talvez queira fazer o gráfico do recurso escolhido no eixo Y versus ImageNumber no eixo X, como nos gráficos do espaço de trabalho, mas fique à vontade para brincar). Se você encontrar uma porta que pareça lógica, proceda como na Etapa 3.

5. Create filters based on the cutoffs you've determined (~10 minutes)

Agora que criamos portas em torno de nossas imagens de baixa qualidade, precisamos convertê-las em filtros para que possamos acessá-las na ferramenta Classifier. Esse processo será desnecessário em versões posteriores do CellProfiler Analyst, mas saber como manipular o arquivo de propriedades é uma habilidade que vale a pena.

- Quando você achar que já examinou gráficos suficientes, é hora de criar filtros com base nos portões que você determinou que contêm imagens ruins. Há duas maneiras de fazer isso:
- Edite o arquivo de propriedades manualmente (recomendado):**
Este método tem a vantagem de que os filtros criados são permanentes; eles não serão perdidos quando você fechar e reabrir o CPA. No entanto, exige que você edite o arquivo de propriedades e, potencialmente, exige que você solucione o que há de errado com a chamada SQL se você digitá-la incorretamente.
 - Em qualquer gráfico que você tenha aberto, abra o Gate Inspector chamando 'gate'-> 'MANAGE GATES'.
 - Abra o arquivo de propriedades em um editor de texto.
 - Na seção Image Filters (Filtros de imagem), crie uma nova linha e inicie-a com

```
filter_SQL_Blurry = SELECT ImageNumber FROM BBBC022QC_Per_Image WHERE
```

- Para cada uma das portas de desfoque ou limite em seu Gate Inspector, copie o texto seguido da palavra OR; por exemplo, se o seu primeiro portão foi:

```
BBBC022QC_Per_Image.Image_ImageQuality_ThresholdOtsu_OrigHoechst_2W BETWEEN "0.00
```

Edite sua instrução SQL para ler:

```
filter_SQL_Blurry = SELECT ImageNumber FROM BBBC022QC_Per_Image WHERE BBBC022QC_Per_Image
```

****NÃO pressione enter**** ou adicione novas linhas entre as diferentes medições; a instrução deve ser uma linha contínua para funcionar.

- Omita o OR após a última medição do portão.
- Repita o procedimento para as portas saturadas, omitindo novamente o último OR, seguindo a instrução

```
filter_SQL_Saturated = SELECT ImageNumber FROM BBBC022QC_Per_Image WHERE
```

- Salve e feche o arquivo de propriedades e, em seguida, abra novamente o CPA.
- **Crie os filtros dentro do CPA (NÃO recomendado)**

Esse método não exige que você edite manualmente o arquivo de propriedades, mas, ao filtrar com base em vários recursos, leva mais tempo para ser configurado, não pode ser editado e precisaria ser repetido sempre que você fechasse e reabrisse o CellProfiler Analyst. Portanto, não é recomendado para uso neste tutorial, mas é apresentado caso você não possa ou não queira editar o arquivo de propriedades.

- Em qualquer gráfico que você tenha aberto, abra o Gate Inspector chamando 'gate' -> 'MANAGE GATES'.
- Copie o texto das portas relevantes em um editor de texto para poder acessá-lo posteriormente.
- Determinar qual é o ponto de corte importante para cada porta (ou seja, para uma porta em que os valores são muito altos, é o valor mínimo; para portas com valores muito baixos, é o valor máximo)
- Abra a caixa de diálogo de criação de filtro selecionando 'filter' -> 'CREATE NEW FILTER'
- Dê um nome ao seu filtro Blurry
- Insira cada corte importante das portas de desfoque ou limiar, selecionando "Add column" (Adicionar coluna) após cada um e alterando a instrução de separação para OR
- Crie um filtro chamado Saturated (Saturado) contendo os cortes importantes das portas de saturação




Figura 3: Criando filtros dentro da CPA

6. Create classifier rules to distinguish good from bad images (~30 minutes)

A criação de gates com base nas 12 medições que representamos graficamente nos ajudou a identificar algumas imagens de baixa qualidade até agora, mas não estamos utilizando o restante de nossas medições e não podemos ter certeza de que encontramos todas elas. Ao criar um classificador de aprendizado de máquina, podemos encontrar recursos que se correlacionam bem com imagens ruins em nosso experimento e aumentar nossa probabilidade de identificar outras imagens de baixa qualidade.



- Abra a ferramenta Classificador (ícone, 2º à esquerda).
- Obtenha 50 imagens aleatórias de ‘experiment’, depois 25 de ‘Blurry’ e ‘Saturated’
- Crie um bom classificador arrastando as imagens para os compartimentos positivos e negativos e treinando com o classificador Fast Gentle Boosting. Se necessário, consulte as instruções do tutorial Translocation para obter lembretes sobre como obter mais imagens, verificar a matriz de confusão do seu classificador etc.
 - Em um experimento maior, você pode decidir adicionar mais compartimentos (para imagens fora de foco, com detritos, com a borda do poço, etc.), mas mantenha dois compartimentos para este experimento.
 - Não busque imagens adicionais apenas dos conjuntos filtrados, certifique-se de extrair algumas do “Random” também, pois seus gates podem não conter todas as imagens ruins do experimento e você deseja um conjunto robusto de imagens de boa qualidade para seu compartimento positivo.
 - Você provavelmente terá que usar mais de 5 regras para obter uma boa classificação - tente definir esse número como 25
- Quando estiver satisfeito com o classificador (este é um experimento pequeno, portanto, não será possível obter uma classificação perfeita, mas busque uma precisão >60% em cada compartimento, pelo menos), examine as regras criadas usando “Advanced”->“Edit rules...”.
- Remova todas as regras que NÃO tenham a ver com ImageQuality (como ‘GroupIndex, etc.) e, em seguida, copie o restante em um editor de texto e salve como um arquivo ‘.txt’. Mantenha o arquivo de texto aberto por enquanto.
- Salve seu conjunto de treinamento para referência futura, se desejar, e feche o CellProfiler Analyst.

7. Add quality control steps to an analysis pipeline (~15 minutes)

Se tiver tempo, você pode adicionar a lista de regras identificadas no classificador de aprendizado de máquina ao pipeline do CellProfiler que corresponde a esse conjunto de dados. Isso pode ser útil no processamento de seus próprios conjuntos de dados grandes, especialmente se o tempo ou a capacidade de computação forem escassos.

- Reabra o CellProfiler e, em seguida, abra o pipeline BBBC022_Analysis (fornecido ou disponível como parte do tutorial “AdvancedSegmentation”).
- Reabra o pipeline BBBC022_QC para referência, em uma janela separada do CellProfiler ou em um editor de texto.
- Clique no botão  para abrir a janela ‘Adicionar módulos’
- Se o seu conjunto de regras contiver regras baseadas em ‘ImageQuality_Threshold’, adicione dois módulos **MeasureImageQuality** (da categoria ‘Measurement’) no topo do seu pipeline, caso contrário, adicione um.
- Configure o(s) módulo(s) **MeasureImageQuality** para que eles forneçam todas as medidas especificadas em seu arquivo de regras; você pode consultar as configurações no pipeline de CQ e/ou no arquivo de regras para determinar quais são.
 - Para as medições que terminam em um número, como “Image_ImageQuality_Correlation_Original_10”, o número se refere à escala “Spatial scale for blur measurements” (Escala espacial para medições de desfoque) especificada. Você começou medindo o desfoque em 4 escalas, mas pode ou não precisar de todas elas com base nas regras selecionadas.
- Adicione o módulo **FlagImage** da categoria ‘Ferramentas de dados’.
- Deixe a categoria da bandeira como “Metadata” e o nome como “QCFlag”
 - Se você tivesse criado muitos compartimentos em sua classificação, definiria esse nome como algo mais descritivo, como “QCDebris”, já que você teria um nome de sinalizador diferente para cada compartimento em seu classificador.
- Deixe a configuração “Skip image set if flagged?” em não

- Seu classificador provavelmente não foi incrivelmente preciso, portanto, definir essa opção como “sim” pode resultar na exclusão de dados reais e, ao mesmo tempo, não excluir todas as imagens ruins. No entanto, se você tivesse muito mais imagens do que achava necessário, poderia definir essa opção como “sim”.
- Defina “Flag is based on” como “Rules” e forneça o caminho e as informações do arquivo de texto das regras.
- Defina o número da classe como qualquer classe em seu conjunto de regras que represente as imagens ruins - esse número será 2 se você mantiver os compartimentos padrão e arrastar as imagens ruins para o compartimento “Negativo”.
- Salve seu pipeline.